

梁泽锋

(+86) 195-2299-8848 zephliang00@gmail.com 求职方向: AI Agent 工程师

个人总结

AI Agent 工程师, 覆盖基础设施、LLM 应用与 Agent Harness 设计三个层面。在字景数科交付了企业级 **Text-to-SQL Agent** 系统——从模型微调到生产级 Harness 工程 (structured error recovery、permission pipeline、context compression、observability)。此前在首都在线设计过大规模异步编排与全链路可观测体系 (Prometheus/Kafka/ELK), 保障核心服务 99.9% SLA。

教育经历

天津师范大学 | 软件工程, 学士 2018.09 – 2022.06

技术能力

- **Agent 架构**: Agent Loop、Tool Calling、Structured Error Recovery (5 类错误分类 + 独立恢复策略)、Permission Pipeline (4 级门控 + 熔断)、Context Compression (3 层: 摘要 → 按需 DDL→ 对话压缩)、Multi-step Planning (Task Graph + 依赖解析)、Cross-session Memory (4 类型分层 + MEMORY.md 索引)、Hook System (PreToolUse/PostToolUse)、Observability (Trace/Metrics)
- **LLM 工程**: RAG (FAISS/Milvus)、LoRA 微调 (CodeLlama-13B)、Prompt Engineering、Text-to-SQL、Execution Accuracy 分级评估
- **基础设施**: Python、Go、Prometheus、Kafka、ELK、Kubernetes、Docker、异步任务编排、熔断降级
- **英语**: IELTS 写作 6.0, 阅读 7.0 (综合 6.0)

工作经历

杭州字景数科 | AI 应用工程师 2024.05 – 2025.08

- **Agent Loop & Structured Error Recovery**: 设计并实现 Agent Loop 与 5 类 SQL 错误分类 (语法/超时/表不存在/权限拒绝/空结果), 每类映射独立恢复策略。工具调用失败率从 ~15% 降至 ~3%
- **Permission Pipeline**: 实现四级 SQL 权限管道 (正则 → 模式 → 白名单 → 用户确认), 非 SELECT 默认拒绝, 连续 3 次拒绝触发自动熔断
- **Observability & 数据驱动优化**: 建立 Trace/Metrics 两层观测, 通过 Metrics 聚合发现 40% 查询失败源于 Schema 字段歧义, 优化后错误率降低 25%
- **Context Compression**: 设计三层上下文压缩 (Table Summary→On-demand DDL→History Compaction), 50+ 表 prompt 控制在 ~4K token, 较纯 RAG 方案减少 60%
- **Multi-step Planning & Cross-session Memory**: 实现多步规划引擎, 复杂查询分解为 3-5 步 SQL Pipeline, 失败步骤隔离重试。引入 4 类型分层记忆跨会话复用查询偏好
- **双模型分工 & Fine-tuning**: 通用 LLM 做 Agent 编排 + CodeLlama-13B (Spider + LoRA rank=16) 专职 SQL 生成。多表 SQL 准确率 33%→77%。RAG Schema Grounding (FAISS) 减少字段错配

北京首都在线 | 后端工程师 2022.05 – 2024.04

- **Async Orchestration**: 将用户云主机配置 (实例规格、GPU、云盘、网络、镜像) 解析为异步任务链——任务间存在依赖与顺序关系 (如先创建实例 → 后挂载云盘 → 后绑定 IP), 每个 task 独立追踪执行状态, 通过 callback handler 串联状态传递与下一步触发, 全部 task 完成后更新 event 状态供运维团队查看。覆盖实例全生命周期 (创建/启动/关机/重启/销毁/重装/变配)、存储 (挂载/卸载/扩容/快照/备份)、网络 (IP/安全组/VPC/带宽)、物理机冷热迁移等操作

- **Telemetry & Logging Infrastructure:** 使用 Prometheus + Kafka + ELK 搭建全链路可观测体系，监控所有异步任务执行状态、底层 API 调用延迟与失败率；设计多级告警策略（限频/分级升级/隔离恢复），团队成员无需登录单机即可排查系统事件
- **Fault Isolation & Recovery:** 底层系统为黑盒 API——任务失败时先定界（参数错误/底层不支持/资源不足），参数问题自动修正重试，底层限制则协调对应团队推动解决。担任生产故障首席响应人，保障 99.9% SLA

项目经历

Text2SQL Agent | 字景数科

2024.05 – 2025.08

- 在 Agent Loop 三个接缝（LLM 调用前/工具执行前/结果返回后）注入策略——权限检查、错误分类、上下文压缩、记忆更新均通过 Hook Pipeline 注册，主循环零修改
- 实现 Hook System (PreToolUse/PostToolUse/SessionStart)，定义 3 态 exit code 协议（0= 继续/1= 拦截/2= 注入上下文）；实现 3 层 Context Compression（摘要 → 按需 DDL→ 对话压缩）+ tiktoken token 预算控制；实现 4 类型分层 Memory + MEMORY.md 索引，SessionStart 自动注入
- 实现 Task Graph 规划引擎——依赖图解析（blockedBy/blocks）、步骤并行调度（ThreadPoolExecutor）、失败隔离重试（不重跑已成功步骤）

云基础设施平台——异步编排 & 全链路可观测 | 首都在线

2022.05 – 2024.04

- **Async Task Orchestration Engine:** 基于 uWSGI spooler 构建异步任务队列——spool 目录文件持久化保证任务不丢，Worker Pool 并发消费，callback handler 串联状态传递，所有子 task 完成后汇总更新 event 状态。调度管线：解析配置 → 拆解任务链（依赖/顺序）→spool 入队 → 并发分发 → 轮询底层 API 状态 → 汇总 event 结果
- **Monitoring & Logging Pipeline:** 搭建 FELK 日志链路（Filebeat→Logstash→Elasticsearch→Kibana）集中化服务器日志，团队成员无需登录单机即可排查。自研 Prometheus Exporter 暴露业务指标，Kafka 作为指标实时缓冲层（利用更新/删除/commit offset 特性），Prometheus scrape→AlertManager 触发告警；告警策略（限频/分级升级/隔离恢复）在业务层实现。Grafana 性能指标面板与 Kibana 日志面板职责分离